

정상 문자를 지키는 스미싱 탐지

문자·URL 결합과 URL 교란 학습의 효과 검증

ScamLens Research Project • 통제 대조실험 및 후속평가 분석

규격: A3 Landscape (420 × 297 mm) • 2026-09

핵심 요약: 개발 단계에서 관측된 URL 교란(FLIP)의 오탐률 개선(~0.21%p)은 과거 평가 이력이 있는 원래 test 세트의 후속평가(U5)에서 재현되지 않았습니다. URL 보유 정상 문자의 오탐률은 2.01~2.35% 수준을 보여 FLIP 채택을 보류하고 DUP를 차기 연구의 통제군으로 유지합니다.

1. 연구 가설 및 배경

정상 문자에도 웹 URL이 빈번히 포함됩니다. 본 연구는 문자 라벨을 보존한 채 URL 유무를 반전(FLIP)하는 학습이 정상 URL 문자의 오탐을 완화하는지 검증했습니다.

2. 대조 실험 설계

BASE (6,680건): 증강 없는 기준 KcBERT 모형

DUP (6,961건): 281건 단순 복제 추가로 데이터 증분 통제

FLIP (6,961건): 281건 URL 유무 반전 증강, 원본 라벨 보존

통제 조건: 배치 32, 3 에폭, 공통 654 updates 예산, 5개 난수 시드(42, 101, 202, 303, 404) 반복.


3. 평가 코호트 분할

1,703건
임계값 캘리브레이션

2,317건
원래 test 후속평가 (U5)

- U5 코호트 구성:** 정상 1,665건, 악성 652건. 과거 평가 이력이 있는 원래 test 세트임.
- 표본 독립성 주의:** 5개 시드는 동일한 2,317건을 반복 평가한 것임.
- 표기 규약:** 5개 시드 평균 ± 모표준편차(Population SD, ddof=0) 표기.

4. 주요 결과: 개발셋 vs U5 후속평가 FPR




개발 단계의 FPR 개선(~0.21%p)은 U5 후속평가에서 재현되지 않았습니다 (관측 FPR: DUP 0.44% vs FLIP 0.46%, 원시 차이 +0.0120%p, 유의성 검정 없음).

5. U5 성능 지표 비교 (5 Seeds)

실험군	오탐률 (FPR, %)	재현율 (Recall, %)
BASE	0.60 ± 0.32	97.82 ± 0.99
DUP	0.44 ± 0.11	97.88 ± 0.48
FLIP	0.46 ± 0.18	97.55 ± 0.85

* 값: 평균 ± 모표준편차(Population SD, ddof=0). 분모: 정상 1,665건 / 악성 652건.
* U5 평가셋에 대한 사후 유의성 검정은 실시하지 않음.

6. 서브그룹: URL 유무별 정상 문자 오탐률



URL 미포함 정상(분모 1,367건)은 0.09~0.22%인 반면, URL 포함 정상(분모 298건)은 2.01~2.35%로 상대적으로 높은 오탐 수준을 보였습니다.

7. SAS 통계 검증 근거

0.9987
문자 단독 AUC

0.9950
고정가중 결합

0.9988
SAS OOF 메타

SAS 서버 배치 환경 ROC 분석 결과 문자 단독과 SAS OOF 메타 모형의 차이는 검출되지 않았습니다 (p=0.7233). 이는 통계적 동등성 증명이 아니며, 서버 배치 기준의 사전 분석으로 로컬 U5 KcBERT 실험과 분리됩니다.

8. 연구 판정 및 한계

연구 의사결정

- U5 후속평가에서 개선이 미재현됨에 따라 FLIP 채택을 보류합니다.
- DUP를 차기 연구의 대조 통제군으로 유지합니다 (배포 승자 모델 아님).

한계점: U5 원본 test는 과거 평가 이력이 존재하며, MPS 환경 비결정성 및 마스킹 미세 차이가 있습니다. 완전한 PII 차단이나 인간 검토 자동 대체 보장은 불가능합니다.