

정상 문자를 지키는 스미싱 탐지

문자·URL 결합과 URL 교란 학습의 효과 검증

SAS 분석 · 대조 실험 · 오탐률 평가

URL만으로는 위험을 설명할 수 없습니다

정상 알림에도 URL이 있습니다

[배송 안내]
배송 현황은 아래에서 확인하세요.
<https://example.invalid/delivery>

URL 없이도 송금을 요구합니다

[가족 사칭]
엄마, 휴대폰이 고장 났어.
급하게 대신 이체해 줄 수 있어?

문자 내용과 URL 단서를 함께 검증해야 합니다.

설명용 합성 문장입니다. 실제 수신 문자나 접속 가능한 분석 대상이 아닙니다.

탐지율과 함께 정상 문자의 오탐을 봅니다

01 재현율 Recall

스미싱 중 찾아낸 비율
 $TP / (TP + FN)$

02 오탐률 FPR

정상 문자 중 스미싱으로 잘못 판단한 비율
 $FP / (FP + TN)$

03 확률 오차 Brier

예측 확률과 정답의 차이 · 작을수록 좋음
평균 $(p - y)^2$

U5 평가 2,317건 = 정상 1,665건 + 스미싱 652건

데이터와 평가 입력부터 고정했습니다

01	출처와 권리 기록	출처·라이선스와 원문 재배포 제한을 기록
02	패턴 기반 마스킹	연락처·계좌 등을 마스킹 자동 탐지의 미탐 가능성과 사람 검수 상태를 별도 기록
03	유사도 그룹 분할	완전 중복 제거 후 유사 문장을 같은 그룹으로 관리
04	중강 코호트 고정	E 281건을 고정하고 기본 fit 입력과 분리

URL은 오프라인 문자열로만 분석했습니다.

SAS에서 결합 모형의 이득을 확인하지 못했습니다

Test AUC

모형	AUC
문자 단독	0.9987
고정가중 결합	0.9950
OOF 기반 결합	0.9988

p = 0.7233

문자 단독 - OOF 결합

AUC 차이 -0.00006

95% CI

[-0.00039, 0.000267]

차이를 검출하지 못했다는 결과이며, 두 모형의 동등성을 증명한 것은 아닙니다.

데이터를 늘린 효과와 URL 교란 효과를 분리했습니다

실험군	학습 데이터 구성	건수
BASE	기본 학습 데이터	6,680
DUP	BASE + E 281건 단순 복제	6,961
FLIP	BASE + E 281건 URL 유무 반전	6,961

세 조건 모두 654회 업데이트 · 5개 시드

FLIP은 정답 레이블을 유지합니다. DUP과 비교해 복제량의 영향을 통제했습니다.


임계값을 정한 뒤 후속 평가에 한 번 적용했습니다

- | | | |
|----|-----------|--|
| 01 | 임계값 선택 | 검교정 1,703건에서 FPR 1% 이하 제약으로 선택 |
| 02 | 모델·임계값 고정 | 체크포인트와 임계값을 기록하고 평가 전 동결 |
| 03 | 후속 평가 U5 | 원래 test 2,317건에 적용
이 분할은 과거 모델 평가에 사용된 이력이 있음 |

1%는 검교정 단계의 선택 기준이며, 서비스 환경의 오탐률을 보장하지 않습니다.

개발셋의 개선은 후속 평가로 이어지지 않았습니다

오탐률 FPR · 낮을수록 좋음



-0.21%p

개발 탐색에서
FLIP - DUP

+0.01%p

U5 후속 평가에서
FLIP - DUP

각 자료 안에서 DUP과 FLIP을 비교했습니다. 차이는 반올림 전 값으로 계산했습니다.
U5 차이에 대한 유의성 검정은 하지 않았습니다.

후속 평가에서도 FLIP을 채택할 근거는 부족했습니다

U5 2,317건 · 5개 시드의 평균 ± 표준편차


조건	재현율 (%)	오탐률 (%)	F1	Brier
BASE	97.82 ± 0.99	0.60 ± 0.32	0.9814 ± 0.0056	0.0091 ± 0.0027
DUP	97.88 ± 0.48	0.44 ± 0.11	0.9837 ± 0.0022	0.0090 ± 0.0016
FLIP	97.55 ± 0.85	0.46 ± 0.18	0.9818 ± 0.0049	0.0117 ± 0.0038

같은 평가 문자를 5개 시드로 반복 평가했습니다. 표준편차는 신뢰구간이 아닙니다.

URL이 있는 정상 문자에서 오탐률이 더 높았습니다

정상 문자의 오탐률

URL 없음 1,367건 / 있음 298건



스미싱 재현율 (%)

URL 없음 54건 / 있음 598건

조건	URL 없음	URL 있음
BASE	94.44	98.13
DUP	93.33	98.29
FLIP	95.19	97.76

두 지표의 분모가 다릅니다. 각 값은 5개 시드의 평균이며, 하위집단 표본 수를 함께 확인해야 합니다.

FLIP 채택을 보류했습니다

DUP을 다음 실험의 비교 기준으로 유지합니다.

01 **추가 검증 후 판단** 개발 탐색에서 낮아진 FPR이 U5에서 재현되지 않음

02 **사후 규칙 별도 관리** Two-track은 개발셋 사후 시뮬레이션
U5에는 적용하지 않음

연구의 다음 조건을 정한 판단입니다. 운영 중인 서비스 모델을 교체한 결과는 아닙니다.

공개 자료에서 확인할 수 있는 범위를 분명히 했습니다

01 집계 결과 계산

공개 JSON과 혼동행렬로 지표를 다시 계산

02 합성 데이터 테스트

원문 없이 전처리·URL 특징·검증기의 동작 확인

03 재학습은 별도 조건

학습 스크립트는 참고용으로 공개
원데이터와 모델 가중치는 공개본에서 제외

공개 결과 탐색 데모는 집계를 보여줍니다. 문자를 입력받아 판정하는 서비스가 아닙니다.

높은 탐지율 다음에는 정상 문자의 오탐을 검증해야 합니다.

이번 검증

URL 교란 학습의 개선이 후속 평가로 이어지지 않음

다음 실험

새 외부 코퍼스 · 정상 URL 표본 확대 · SAS 검증 연결

시드별 결과 · 15개 모델 전체

Recall = $TP/(TP+FN)$ · FPR = $FP/(FP+TN)$ · Brier = 평균 $(p-y)^2$

시드	조건	임계값	재현율	오탐률	F1	Brier
42	BASE	0.0329	96.47%	0.90%	0.9707	0.0142
42	DUP	0.0251	98.47%	0.48%	0.9862	0.0110
42	FLIP	0.2482	98.47%	0.54%	0.9854	0.0069
101	BASE	0.0439	98.77%	0.72%	0.9847	0.0073
101	DUP	0.0605	98.16%	0.42%	0.9854	0.0079
101	FLIP	0.0406	97.39%	0.42%	0.9815	0.0146
202	BASE	0.3418	96.78%	0.06%	0.9829	0.0088
202	DUP	0.9858	97.24%	0.24%	0.9829	0.0068
202	FLIP	0.3012	98.16%	0.18%	0.9884	0.0071
303	BASE	0.8012	98.47%	0.42%	0.9869	0.0063
303	DUP	0.0221	97.39%	0.54%	0.9799	0.0106
303	FLIP	0.0574	96.01%	0.42%	0.9743	0.0149
404	BASE	0.0206	98.62%	0.90%	0.9817	0.0089
404	DUP	0.0261	98.16%	0.54%	0.9839	0.0086
404	FLIP	0.0403	97.70%	0.72%	0.9792	0.0147

개인정보 처리와 공개 범위

항목	처리·공개 범위	남은 조건
연락처·계좌 등	패턴 기반 마스킹	자동 탐지의 미탐 가능
문자 원문·행별 예측	공개본에서 제외	원데이터 재현은 별도 승인 필요
모델 가중치	공개본에서 제외	공개 데모는 집계 결과만 탐색
사람 검수	완료 상태를 별도 기록	전수 검수 완료로 표현하지 않음

출처·권리: docs/PROVENANCE.md · 해석 한계: docs/LIMITATIONS.md

후속 평가의 해석 범위

항목	현재 상태
평가 독립성	원래 test 분할에는 과거 모델 평가에 사용된 이력이 있음
가중치 연속성	09-17 가중치를 보존하지 못해 새 가중치로 재학습
실행 재현성	Apple Silicon MPS 실행 · 비트 단위 동일성은 보장하지 않음
정상 URL 표본	298건으로 규모가 작아 추가 표본 필요
전처리 차이	학습과 평가 데이터의 이름 토큰 마스킹 수준 차이 존재

새 외부 코퍼스와 통일된 전처리 조건에서 추가 검증이 필요합니다.

SAS 분석과 사후 시뮬레이션을 구분합니다

구분	SAS 분석	Two-track
입력·평가	메타 학습: OOF 예측 ROC 비교: test 점수	개발 탐색 1,750건
방법	PROC LOGISTIC 기반 결합·비교	개발 결과를 보고 만든 사후 규칙
해석	결합 모형의 차이 미검출 동등성을 증명한 결과는 아님	U5에 적용하지 않음 본편 확증 성과에 포함하지 않음

이전 SAS 실행 결과와 이번 Python/MPS U5 후속 평가는 별도 실행입니다.

질의응답 · 공개본에서 바로 확인하기

결과 재검산

```
python3 scripts/verify_public_results.py
```

합성 데이터 테스트

```
python3 -m unittest discover -s tests -v
```

집계 탐색 데모

```
python3 demo/result_explorer.py --summary
```

근거 자료

```
data/public_results/ reports/ docs/
```

모든 명령은 공개 배포 폴더 scamlens/를 기준으로 실행합니다.