

정상 문자를 지키는 스미싱 탐지 검증

집계 재검증과 입력 개입 진단

기존 평가 · KISA 외부 진단 · JEV 실험 · SAS 검증

정상 경보와 미탐을 함께 검증합니다

정상 문자의 오탐을 줄이면서

스미싱을 정밀하게 탐지하려면 무엇을 검증해야 하는가

- 오탐 통제: 정상 문자를 스미싱으로 잘못 판단하지 않는지 본다
- 미탐 점검: 스미싱을 정상으로 놓치지 않는지 본다
- 재현성: 같은 집계에서 다시 계산해도 같은 수치인지 확인한다

악성 탐지율보다 정상 사용자 오탐 통제와 후속 평가 재현성을 검증하는 연구다.

각 평가는 역할이 다릅니다

평가	자료	규모	해석 범위
기존 U5	과거 평가 이력 있음	2,317건	기존 시험·사후 진단
KISA 외부	양성만	22건	외부 사례 탐지
정상 후보	개발용	250건	경보 증가 점검
JEV 대체	오류 과대표 집	88건	바꿨을 때 득실
JEV 결합	검증자료 나눔	142건	추가 효과 탐색

대표 18건은 고유 22건의 부분집합이라 합산하지 않는다.

데이터와 임계값을 먼저 고정했습니다

- URL은 오프라인 문자열로만 분석하고 외부에 접속하지 않았다
- 완전 중복 제거 후 유사 문장을 같은 그룹으로 관리했다
- 임계값은 평가 전에 정하고 5개 시드별 값을 모든 입력 조건에 동일하게 적용했다
- 입력 개입은 사후 진단으로 구분하고 최종 모델의 임계값을 유지했다

시드: 42, 101, 202, 303, 404. 같은 문자의 반복 판정을 새 문자로 세지 않는다.

세 조건을 같은 방식으로 비교했습니다

조건	학습 데이터	시드
BASE	원본 학습	5개
DUP	선택 원문 추가	5개
FLIP	선택 문자 URL 편집문 추가	5개

FLIP은 정답 라벨을 유지합니다. 라벨을 반전한 조건이 아닙니다.

FLIP은 URL 편집문을 추가하되 원래 정답을 그대로 둔다.

사전 SAS 분석은 U5와 별개 실행입니다

모형	AUC
문자 단독	0.9987
SAS OOF 메타	0.9988
고정가중 결합	0.9950

p = 0.7233

문자 단독 - OOF 결합

AUC 차이 -0.00006
95% CI
[-0.00039, 0.00027]

차이가 검출되지 않았다는 결과이며 동등성 증명이 아니다. p값을 U5 결과에 적용하지 않는다.

DUP 평균이 가장 낮았으나 우월 확정은 아닙니다

U5 2,317건 · 5개 시드 평균


조건	평균 오탐	평균 미탐	평균 탐지율	평균 오탐률
BASE	10.0건	14.2건	97.82%	0.60%
DUP	7.4건	13.8건	97.88%	0.44%
FLIP	7.6건	16.0건	97.55%	0.46%

같은 평가 문자를 5개 시드로 반복 평가했다. 평균 비교이며 통계적 우월 판정이 아니다.

URL이 있는 정상 문자에서 오탐률이 높았습니다

정상 문자의 평균 오탐률

URL 없음 1,367건 / 있음 298건




같은 분모가 아님에 주의

두 집단의 분모가 다르다. 연관 관찰이며 URL 단일 원인으로 확정하지 않는다.

긴 문자에 미탐이 집중됐습니다

128토큰 기준



초과 스미싱 57건
미탐률 16.84%

뒤쪽 절단만을 원인으로 확정할 수 없다. 문체·출처가 함께 몰려 있을 수 있다.

외부 22건 중 13건을 탐지했습니다

집합	탐지 / 미탐	탐지율
고유	13 / 9	59.09%
대표(부분 집합)	9 / 9	50.00%

기준 시드 42 · 정상 문자 없음 · 오탐률 계산 불가

소표본 결과이며 전체 환경 탐지율로 일반화하지 않는다.

탐지와 정상 경보를 함께 봅니다

시드 42 · KISA 고유 22건 · 개발 정상 후보 250건

입력 처리	탐지/미탐	탐지율	정상 경고	새 경고
기존 128토큰	13/9	59.09%	11건	0건
화면 잡음 삭제 + 128토큰	13/9	59.09%	11건	0건
읽는 범위 300토큰 확대	13/9	59.09%	24건	13건
화면 잡음 삭제 + 300토큰	14/8	63.64%	24건	13건
화면 잡음 가림 + 128토큰	13/9	59.09%	11건	0건
화면 잡음 가림 + 300토큰	16/6	72.73%	24건	13건
앞부분·뒷부분 합성 128토큰	13/9	59.09%	17건	6건

일부 복구는 탐색적 관찰이다. 사후 승자 교체를 하지 않는다.

두 JEV 실험은 서로 다릅니다

자동 대체 · 선택 88건 / 시드 42

결과	건수
기존 오탐 해소	8건
새 미탐 발생	41건
정답→보류	1건

특징 결합 · 재사용 142건

결합	오탐	미탐
기준선	0건	0건
점수 재결합	0건	0건
+ JEV	0건	0건
+ URL	1건	0건
+ JEV + URL	0건	0건

대체 실험은 미채택. 결합 실험은 기준선 무오류라 이득 입증 여지가 없었다.

기존 조건과 고정 임계값을 유지합니다

original128과 시드별 고정 임계값을 그대로 둔다.

- 사전 후보 head_tail128은 5개 시드 모두 미탐 복구 없이 새 경보 발생으로 불통과
- 관측 후 가장 좋아 보이는 조건으로 승자를 바꾸지 않는다
- 개선 효과의 신규 독립 시험으로 표현하지 않는다

채택하지 않을 방법을 가려낸 검증 과정이 이번 판단의 내용이다.

SAS 반환은 검증했고 새 그림은 실행 대기 중입니다

- 집계 반환 4단계 완료 · ZIP 55개 무결성 · 그래프 35개 검수
- SAS 계산·반환 검증 통과와 탐지 성능 개선은 다른 판단이다
- 새 SAS Studio 발표용 그림과 Visual Analytics 대시보드는 사용자 서버 실행 대기 중이며 실제 가동을 주장하지 않는다

Studio 보고서 생성 → CAS 집계 계산·게시 → VA 보고서 구성·저장

오류가 모이는 조건과 시도한 수정의 득실을 가려냈습니다.

한계	원인 단일 확정 아님 · 실서비스 안전성 입증 아님
다음	새 독립 자료에서 사전 고정된 비교

입력 조건 상세와 시드 한계

- 화면 잡음 삭제: 상태바·작성창 구간 제거. 뒤쪽 토큰 위치가 바뀔 수 있다. 배포용 자동 정제 규칙이 아니다
- 화면 잡음 가림: 위치·길이 유지 [UNK] 치환. 자연 정제문과 다르다
- 300토큰 확대: 128토큰 학습 모형의 읽기 범위 실험. 새로 학습한 모형 검증이 아니다
- 앞뒤 합성은 기존 진단 규칙 그대로. 짧은 입력은 원래 입력과 동일하다
- KISA 진단은 동일 자료 재사용 사후 진단. 기존 시드 외 개선 폭이 일정하지 않다

지표와 자료의 한계

항목	현재 상태
탐지율	스미싱 중 탐지 비율. 전체 정확도와 다름
오탐률	정상 문자 분모. KISA 양성만으로 계산 불가
5시드 평균	같은 문자 반복 판정. 고유 문자 수로 읽지 않음
정상 후보	개발용. 독립 오탐률·인증 정상 아님
대표 집합	고유 집합 부분집합. 합산 금지

자료를 반복 조회해 맞춘 결과를 독립 개선 성과로 제시하지 않는다.

증거와 재생성

정본 JSON에서 다시 계산

reports/generated/submission_final_20260921.json

증거 검사

python3 scripts/build_submission_final_20260921.py --check

덱 검사

node scripts/build_submission_deck_final_20260921.mjs --check

자료 범위

원문·행별 예측·개인 식별자·가중치 제외

새 추론·API·학습·임계값 조정이 없다.